Ανάλυση Δεδομένων 2025-26

1η Εργασία: Καθαρισμός και Ανάλυση Δεδομένων Ποιότητας Κρασιού

Ερώτημα 1: Δειγματοληψία και Καθαρισμός Δεδομένων

ΑΕΜ: 6931

Μάρτιος 2026

Contents

1 Εισαγωγή

1.1 Σκοπός της Εργασίας

Η παρούσα εργασία αφορά την ανάλυση ενός συνόλου δεδομένων (dataset) που περιέχει χαρακτηριστικά ποιότητας διαφόρων τύπων κρασιού. Ο στόχος του πρώτου ερωτήματος είναι:

1. Η επιλογή ενός **τυχαίου δείγματος** που αποτελεί το 80% των αρχικών δεδομένων
2. Ο **έλεγχος ποιότητας** των δεδομένων για τον εντοπισμό προβλημάτων
3. Ο **καθαρισμός** των δεδομένων με κατάλληλες τεχνικές

1.2 Τι είναι ο Καθαρισμός Δεδομένων;

Ορισμός: Καθαρισμός Δεδομένων (Data Cleaning)

Ο καθαρισμός δεδομένων είναι η διαδικασία εντοπισμού και διόρθωσης (ή αφαίρεσης) λανθασμένων, ελλιπών, διπλότυπων ή ασυνεπών εγγραφών από ένα σύνολο δεδομένων. Είναι ένα κρίσιμο βήμα πριν από οποιαδήποτε ανάλυση, καθώς η ποιότητα των αποτελεσμάτων εξαρτάται άμεσα από την ποιότητα των δεδομένων.

1.3 Γιατί είναι Σημαντικός ο Καθαρισμός Δεδομένων;

Τα πραγματικά δεδομένα σπάνια είναι τέλεια. Συνήθη προβλήματα περιλαμβάνουν:

- **Τυπογραφικά λάθη:** Λανθασμένη πληκτρολόγηση (π.χ. “whte” αντί “white”)
- **Ελλείπουσες τιμές (Missing Values):** Κενά πεδία σε ορισμένες εγγραφές
- **Μη έγκυρες τιμές:** Τιμές εκτός λογικών ορίων (π.χ. pH = 999)
- **Διπλοεγγραφές:** Η ίδια εγγραφή εμφανίζεται πολλές φορές

Αν δεν αντιμετωπιστούν αυτά τα προβλήματα, τα αποτελέσματα της ανάλυσης θα είναι αναξιόπιστα ή παραπλανητικά.

2 Περιγραφή του Συνόλου Δεδομένων

2.1 Πηγή και Περιεχόμενο

Το σύνολο δεδομένων περιέχει μετρήσεις χημικών χαρακτηριστικών κρασιών (κόκκινων και λευκών) μαζί με βαθμολογίες ποιότητας. Κάθε γραμμή αντιπροσωπεύει ένα δείγμα κρασιού.

2.2 Μεταβλητές του Dataset

Table 1: Περιγραφή των μεταβλητών του dataset

Α/Α	**Μεταβλητή**	**Περιγραφή**
1	Fixed acidity	Σταθερή οξύτητα - Μη πτητικά οξέα (g/L)
2	Volatile acidity	Πτητική οξύτητα - Οξικό οξύ (g/L)
3	Citric acid	Κιτρικό οξύ (g/L)
4	Residual sugar	Υπολειμματικά σάκχαρα μετά τη ζύμωση (g/L)
5	Chlorides	Χλωριούχα άλατα - Δείκτης αλατότητας (g/L)
6	Free sulfur dioxide	Ελεύθερο SO_2 - Προστασία από οξείδωση (mg/L)
7	Total sulfur dioxide	Συνολικό SO_2 (ελεύθερο + δεσμευμένο) (mg/L)
8	Density	Πυκνότητα (g/cm^3)
9	pH	Μέτρο της οξύτητας (κλίμακα 0-14)
10	Sulphates	Θειικά άλατα (g/L)
11	Alcohol	Περιεκτικότητα σε αιθανόλη (% vol)
12	Quality	Βαθμολογία ποιότητας (κλίμακα 0-10)
13	Wine_type	Τύπος κρασιού: red (κόκκινο) ή white (λευκό)

Τύποι Μεταβλητών

- **Συνεχείς (Continuous):** Μεταβλητές 1-11 - μπορούν να πάρουν οποιαδήποτε αριθμητική τιμή σε ένα εύρος
- **Διακριτές/Κατηγορικές:** Quality (διακριτή κλίμακα 0-10), Wine_type (κατηγορική με τιμές "red" ή "white")

2.3 Αρχικές Διαστάσεις

Το αρχικό dataset περιείχε:

- **8.385 γραμμές** (εγγραφές/δείγματα κρασιού)
- **15 στήλες** (13 μεταβλητές + 2 κενές στήλες)

3 Δειγματοληψία (Sampling)

3.1 Τι είναι η Δειγματοληψία;

Ορισμός: Δειγματοληψία

Η δειγματοληψία είναι η διαδικασία επιλογής ενός υποσυνόλου (δείγματος) από ένα μεγαλύτερο σύνολο δεδομένων (πληθυσμό). Χρησιμοποιείται για να μειώσει τον όγκο των δεδομένων προς ανάλυση ή για να δημιουργήσει διαφορετικά σύνολα για εκπαίδευση και αξιολόγηση μοντέλων.

3.2 Γιατί τυχαία δειγματοληψία;

Η **τυχαία δειγματοληψία** εξασφαλίζει ότι:

1. Κάθε εγγραφή έχει **ίση πιθανότητα** να επιλεγεί
2. Το δείγμα είναι **αντιπροσωπευτικό** του συνόλου
3. Αποφεύγεται η **μεροληψία** (bias) στην επιλογή

3.3 Ο Ρόλος του Seed (Σπόρος)

Σημαντικό: Random Seed

Οι υπολογιστές δημιουργούν "ψευδοτυχαίους" αριθμούς χρησιμοποιώντας αλγορίθμους. Ο **seed** (σπόρος) είναι μια αρχική τιμή που καθορίζει την ακολουθία των τυχαίων αριθμών.
Γιατί είναι σημαντικό: Χρησιμοποιώντας τον ίδιο seed, παίρνουμε πάντα τα ίδια "τυχαία" αποτελέσματα. Αυτό επιτρέπει την **αναπαραγωγιμότητα** (reproducibility) της ανάλυσης.
Στην εργασία, χρησιμοποιούμε ως seed τον AEM (6931), ώστε κάθε φοιτητής να εργάζεται με διαφορετικό δείγμα.

3.4 Υλοποίηση στην Python

```python
import pandas as pd

#
df_original = pd.read_csv('Data Analysis_2026 1st Case_Data.csv')

#
AEM = 6931                #                  (seed)
SAMPLE_FRACTION = 0.80    #                                  (80%)

#
df = df_original.sample(frac=SAMPLE_FRACTION, random_state=AEM)

#                      index
df = df.reset_index(drop=True)
```

Listing 1: Κώδικας δειγματοληψίας

Επεξήγηση του κώδικα:

- `sample()`: Η συνάρτηση της pandas για τυχαία επιλογή γραμμών
- `frac=0.80`: Επιλέγουμε το 80% των γραμμών
- `random_state=AEM`: Ορίζουμε τον seed για αναπαραγωγιμότητα
- `reset_index()`: Επαναριθμούμε τις γραμμές από 0

3.5 Αποτέλεσμα Δειγματοληψίας

Table 2: Αποτελέσματα δειγματοληψίας

Μέγεθος	**Γραμμές**	**Ποσοστό**
Αρχικό dataset	8.385	100%
Δείγμα (AEM: 6931)	6.708	80%

4 Εντοπισμός Προβλημάτων στα Δεδομένα

Μετά τη δειγματοληψία, πραγματοποιήθηκε συστηματικός έλεγχος για τον εντοπισμό προβλημάτων. Τα προβλήματα οργανώθηκαν σε τέσσερις κατηγορίες.

4.1 Κατηγορία 1: Τυπογραφικά Λάθη στη Στήλη wine_type

4.1.1 Τι ελέγξαμε

Η στήλη `wine_type` πρέπει να περιέχει μόνο δύο τιμές: "red" ή "white". Ελέγξαμε τις μοναδικές τιμές που εμφανίζονται:

```
#
print(df['wine_type'].unique())
```

Listing 2: Έλεγχος μοναδικών τιμών

4.1.2 Τι βρήκαμε

Table 3: Τυπογραφικά λάθη στη στήλη wine_type

Λανθασμένη Τιμή	Πλήθος Εμφανίσεων	Πιθανή Σωστή Τιμή
Redd	75	red
whit	90	white
r3d	64	red
WHITTE	77	white
whate	39	white
999	59	Μη έγκυρη
9999	45	Μη έγκυρη
-999	64	Μη έγκυρη
?	47	Μη έγκυρη
Σύνολο	**560**	

Ανάλυση των λαθών

- **"Redd ", "r3d"**: Παραλλαγές του "red" με τυπογραφικά λάθη ή κενά
- **"whit", "WHITTE", "whate"**: Παραλλαγές του "white"
- **"999", "9999", "-999", "?"**: Κωδικοί που πιθανώς χρησιμοποιήθηκαν για να δηλώσουν ελλείπουσες ή άγνωστες τιμές

4.2 Κατηγορία 2: Μη Αριθμητικές Τιμές σε Αριθμητικές Στήλες

4.2.1 Τι ελέγξαμε

Οι 12 μεταβλητές (εκτός του wine_type) πρέπει να περιέχουν αριθμητικές τιμές. Ελέγξαμε αν υπάρχουν τιμές που δεν μπορούν να μετατραπούν σε αριθμούς.

```
#                                errors='coerce'
                                     NaN
df['fixed acidity'] = pd.to_numeric(df['fixed acidity'], errors='coerce'
    )
```

Listing 3: Μετατροπή σε αριθμητικές τιμές

4.2.2 Τι βρήκαμε

Table 4: Μη αριθμητικές τιμές ανά στήλη

Μεταβλητή	**Μη αριθμητικές τιμές**
fixed acidity	87
volatile acidity	45
citric acid	61
residual sugar	56
chlorides	57
free sulfur dioxide	56
total sulfur dioxide	53
density	53
pH	151
sulphates	63
alcohol	105
quality	58
Σύνολο	**845**

4.3 Κατηγορία 3: Αδύνατες/Ακραίες Τιμές

4.3.1 Τι ελέγξαμε

Ακόμα και αν μια τιμή είναι αριθμητική, μπορεί να είναι **αδύνατη** ή **μη ρεαλιστική**. Ορίσαμε λογικά όρια για κάθε μεταβλητή βάσει επιστημονικής γνώσης:

Table 5: Λογικά όρια τιμών ανά μεταβλητή

Μεταβλητή	**Min**	**Max**	**Αιτιολόγηση**
Fixed acidity	0	20	Τυπικές τιμές 4-16 g/L
Volatile acidity	0	5	Τυπικές τιμές 0.1-1.5 g/L
Citric acid	0	3	Τυπικές τιμές 0-1 g/L
Residual sugar	0	100	Ξηρά κρασιά ¡4, γλυκά ως 100 g/L
Chlorides	0	1	Τυπικές τιμές 0.01-0.2 g/L
Free SO_2	0	300	Νομικό όριο 300 mg/L
Total SO_2	0	500	Νομικό όριο 400 mg/L
Density	0.9	1.1	Κοντά στο νερό (1 g/cm^3)
pH	2	5	Κρασί: τυπικά 2.9-4.0
Sulphates	0	3	Τυπικές τιμές 0.3-1.5 g/L
Alcohol	5	20	Κρασί: τυπικά 8-15%
Quality	0	10	Κλίμακα βαθμολόγησης

4.3.2 Τι βρήκαμε

Table 6: Αδύνατες τιμές ανά μεταβλητή

Μεταβλητή	**Πλήθος**	**Παραδείγματα**
fixed acidity	156	999, -999, 9999
volatile acidity	170	999, -999, 9999
citric acid	164	999, -999, 9999
residual sugar	165	999, -999, 9999
chlorides	161	999, -999, 9999
free sulfur dioxide	151	999, -999, 9999
total sulfur dioxide	160	999, -999, 9999
density	154	999, -999, 9999
pH	202	0, 999, -999, 9999
sulphates	160	999, -999, 9999
alcohol	197	999, -999, 9999
quality	197	999, -999, 9999
Σύνολο	**2.037**	

Παρατήρηση

Οι τιμές 999, -999 και 9999 εμφανίζονται συστηματικά σε όλες τις στήλες. Αυτό υποδηλώνει ότι χρησιμοποιήθηκαν **ως κωδικοί για ελλείπουσες τιμές** κατά την καταχώρηση των δεδομένων, αντί να αφεθούν κενά τα πεδία.

4.4 Κατηγορία 4: Διπλοεγγραφές (Duplicates)

4.4.1 Τι είναι οι διπλοεγγραφές

Μια διπλοεγγραφή είναι μια γραμμή που εμφανίζεται **πανομοιότυπη** με άλλη γραμμή στο dataset. Αυτό μπορεί να συμβεί από:

- Λάθος κατά την εισαγωγή δεδομένων
- Συγχώνευση πολλαπλών αρχείων χωρίς έλεγχο
- Τεχνικά προβλήματα κατά την αποθήκευση

4.4.2 Τι βρήκαμε

```
#
duplicates = df.duplicated()
print(f"                                        : {duplicates.sum()}")
```

Listing 4: Εντοπισμός διπλοεγγραφών

Αποτέλεσμα

Εντοπίστηκαν **1.434 διπλοεγγραφές** στο δείγμα.

4.5 Κατηγορία 5: Ελλείπουσες Τιμές (Missing Values)

4.5.1 Τι είναι οι ελλείπουσες τιμές

Ορισμός: Missing Values

Οι ελλείπουσες τιμές (ή NaN - Not a Number) είναι θέσεις στο dataset όπου δεν υπάρχει καταχωρημένη τιμή. Μπορεί να προκύψουν από:

- Αδυναμία μέτρησης ή καταγραφής
- Λάθη κατά τη μεταφορά δεδομένων
- Μετατροπή μη έγκυρων τιμών σε NaN (όπως στη δική μας περίπτωση)

4.5.2 Τι βρήκαμε

Μετά τη μετατροπή των μη έγκυρων τιμών σε NaN, έχουμε:

Table 7: Ελλείπουσες τιμές ανά μεταβλητή

Μεταβλητή	**Missing Values**	**Ποσοστό**
fixed acidity	574	10.88%
volatile acidity	542	10.28%
citric acid	1	0.02%
residual sugar	134	2.54%
chlorides	8	0.15%
free sulfur dioxide	1	0.02%
total sulfur dioxide	1	0.02%
density	545	10.33%
pH	644	12.21%
sulphates	1	0.02%
alcohol	600	11.38%
quality	40	0.76%
wine_type	1	0.02%
Σύνολο	**3.092**	

5 Αντιμετώπιση Προβλημάτων

5.1 Στρατηγική Αντιμετώπισης

Για κάθε κατηγορία προβλήματος, εφαρμόσαμε κατάλληλη στρατηγική:

Table 8: Στρατηγική αντιμετώπισης ανά τύπο προβλήματος

Πρόβλημα	**Στρατηγική Αντιμετώπισης**
Τυπογραφικά λάθη	Διόρθωση στη σωστή τιμή ή μετατροπή σε NaN
Μη αριθμητικές τιμές	Μετατροπή σε NaN
Αδύνατες τιμές	Μετατροπή σε NaN
Διπλοεγγραφές	Αφαίρεση (κράτηση μόνο της πρώτης εμφάνισης)
Missing values	Συμπλήρωση με τη διάμεσο (median) ανά τύπο κρασιού

5.2 Διόρθωση Τυπογραφικών Λαθών

```
#
wine_type_corrections = {
    'Redd ': 'red',      #
    'r3d': 'red',        #                                        (
                    3           e)
    'WHITTE': 'white',   #
    'whit': 'white',     #
    'whate': 'white',    #
    '999': np.nan,       #

    '9999': np.nan,      #

    '-999': np.nan,      #

    '?': np.nan,         #
}

#
for wrong, correct in wine_type_corrections.items():
    mask = df['wine_type'] == wrong
    df.loc[mask, 'wine_type'] = correct
```

Listing 5: Διόρθωση τυπογραφικών λαθών

Αποτέλεσμα

Διορθώθηκαν **560 εγγραφές** με τυπογραφικά λάθη στη στήλη wine_type.

5.3 Αντιμετώπιση Αδύνατων Τιμών

```
#
value_limits = {
    'fixed acidity': (0, 20),
    'volatile acidity': (0, 5),
    'pH': (2, 5),
    # ...
}

#
for col, (min_val, max_val) in value_limits.items():
    #
```

```
    out_of_range = (df[col] < min_val) | (df[col] > max_val)
    #                                   NaN
    df.loc[out_of_range, col] = np.nan
```

Listing 6: Αντικατάσταση αδύνατων τιμών

5.4 Αφαίρεση Διπλοεγγραφών

```
#                                                ,

df = df.drop_duplicates()
df = df.reset_index(drop=True)
```

Listing 7: Αφαίρεση διπλοεγγραφών

Αποτέλεσμα

Αφαιρέθηκαν **1.434 διπλοεγγραφές**.

5.5 Συμπλήρωση Ελλειπουσών Τιμών

5.5.1 Επιλογή Μεθόδου: Διάμεσος (Median)

Γιατί Διάμεσος και όχι Μέσος Όρος;

- Η **διάμεσος** είναι η μεσαία τιμή όταν τα δεδομένα ταξινομηθούν
- Είναι **ανθεκτική** σε ακραίες τιμές (robust)
- Ο **μέσος όρος** επηρεάζεται πολύ από ακραίες τιμές
- Για δεδομένα με ασυμμετρία (skewness), η διάμεσος είναι καταλληλότερη

5.5.2 Γιατί ανά τύπο κρασιού;

Τα κόκκινα και λευκά κρασιά έχουν **διαφορετικά χημικά χαρακτηριστικά**:

Table 9: Σύγκριση διαμέσων τιμών ανά τύπο κρασιού

Μεταβλητή	Κόκκινο	Λευκό
Fixed acidity	7.80	6.80
Volatile acidity	0.50	0.26
Total sulfur dioxide	40	133
Alcohol	10.20	10.40

Αν χρησιμοποιούσαμε τη συνολική διάμεσο, θα εισάγαμε σφάλμα στις εκτιμήσεις.

5.5.3 Υλοποίηση

```
#
for col in numeric_columns:
    #
    for wine_type in ['red', 'white']:
        #                                        missing value
        mask = (df['wine_type'] == wine_type) & (df[col].isnull())

        #

        median_val = df.loc[df['wine_type'] == wine_type, col].median()

        #                              missing
        df.loc[mask, col] = median_val

#                                  wine_type,            mode (
                          )
mode_wine = df['wine_type'].mode()[0]  # 'white'
df['wine_type'] = df['wine_type'].fillna(mode_wine)
```

Listing 8: Συμπλήρωση missing values με διάμεσο

6 Συνοπτικά Αποτελέσματα

6.1 Πίνακας Προβλημάτων και Αντιμετώπισης

Table 10: Συνοπτικός πίνακας προβλημάτων

Τύπος Προβλήματος	**Πλήθος**	**Αντιμετώπιση**
Περιττές στήλες (Unnamed)	2	Αφαίρεση
Τυπογραφικά λάθη wine_type	9 τύποι (560)	Διόρθωση/NaN
Μη αριθμητικές τιμές	845	Μετατροπή σε NaN
Αδύνατες/ακραίες τιμές	2.037	Μετατροπή σε NaN
Διπλοεγγραφές	1.434	Αφαίρεση
Missing values (αρχικά)	3.092	Συμπλήρωση με διάμεσο
Missing values (τελικά)	0	–

6.2 Μεταβολή Μεγέθους Dataset

Στάδιο	**Γραμμές**	**Στήλες**
Αρχικό dataset	8.385	15
Μετά δειγματοληψία (80%)	6.708	13
Μετά αφαίρεση διπλοεγγραφών	5.274	13
Τελικό καθαρό dataset	**5.274**	**13**

Figure 1: Εξέλιξη μεγέθους dataset

6.3 Κατανομή Τελικού Dataset

Table 11: Κατανομή τελικού dataset ανά τύπο κρασιού

Τύπος Κρασιού	**Πλήθος**	**Ποσοστό**
Λευκό (white)	3.924	74.4%
Κόκκινο (red)	1.350	25.6%
Σύνολο	**5.274**	**100%**

7 Συμπεράσματα

7.1 Τι Μάθαμε

1. Τα πραγματικά δεδομένα περιέχουν **πολλαπλά είδη προβλημάτων**
2. Ο καθαρισμός δεδομένων είναι **απαραίτητο προκαταρκτικό βήμα**
3. Κάθε τύπος προβλήματος απαιτεί **διαφορετική αντιμετώπιση**
4. Οι αποφάσεις καθαρισμού πρέπει να είναι **τεκμηριωμένες και αναπαραγώγιμες**

7.2 Περιορισμοί

- Η συμπλήρωση με διάμεσο **μειώνει τη μεταβλητότητα** των δεδομένων
- Η αφαίρεση διπλοεγγραφών **μείωσε το μέγεθος** του dataset κατά 21%
- Ορισμένες αποφάσεις (π.χ. όρια τιμών) βασίστηκαν σε **εμπειρική γνώση**

7.3 Επόμενα Βήματα

Το καθαρισμένο dataset είναι πλέον έτοιμο για:

- Περιγραφική στατιστική ανάλυση
- Οπτικοποίηση (boxplots, histograms, κλπ.)
- Εντοπισμό ακραίων τιμών (outliers)
- Κατασκευή προβλεπτικών μοντέλων

A Παράρτημα: Πλήρης Κώδικας Python

```python
import pandas as pd
import numpy as np

#
df_original = pd.read_csv('Data Analysis_2026 1st Case_Data.csv')

```

```python
#
unnamed_cols = [col for col in df_original.columns if 'Unnamed' in col]
df_original = df_original.drop(columns=unnamed_cols)

#
AEM = 6931
df = df_original.sample(frac=0.80, random_state=AEM)
df = df.reset_index(drop=True)

#
wine_type_corrections = {
    'Redd ': 'red', 'r3d': 'red',
    'WHITTE': 'white', 'whit': 'white', 'whate': 'white',
    '999': np.nan, '9999': np.nan, '-999': np.nan, '?': np.nan
}
for wrong, correct in wine_type_corrections.items():
    df.loc[df['wine_type'] == wrong, 'wine_type'] = correct

#
numeric_columns = ['fixed acidity', 'volatile acidity', 'citric acid',
                   'residual sugar', 'chlorides', 'free sulfur dioxide',
                   'total sulfur dioxide', 'density', 'pH', 'sulphates',
                   'alcohol', 'quality']
for col in numeric_columns:
    df[col] = pd.to_numeric(df[col], errors='coerce')

#
value_limits = {
    'fixed acidity': (0, 20), 'volatile acidity': (0, 5),
    'citric acid': (0, 3), 'residual sugar': (0, 100),
    'chlorides': (0, 1), 'free sulfur dioxide': (0, 300),
    'total sulfur dioxide': (0, 500), 'density': (0.9, 1.1),
    'pH': (2, 5), 'sulphates': (0, 3), 'alcohol': (5, 20),
    'quality': (0, 10)
}
for col, (min_val, max_val) in value_limits.items():
    mask = (df[col] < min_val) | (df[col] > max_val)
    df.loc[mask, col] = np.nan

#
df = df.drop_duplicates().reset_index(drop=True)

#                       missing values
df['wine_type'] = df['wine_type'].fillna(df['wine_type'].mode()[0])
for col in numeric_columns:
    for wine_type in ['red', 'white']:
        mask = (df['wine_type'] == wine_type) & (df[col].isnull())
        median = df.loc[df['wine_type'] == wine_type, col].median()
        df.loc[mask, col] = median

#
df.to_csv('cleaned_wine_data_AEM_6931.csv', index=False)
```

Listing 9: Πλήρης κώδικας καθαρισμού δεδομένων